

Intención de compra en e-commerce

Pre-entrega 1 · Selección y validación del dataset

Mateo Sapia | 29 de septiembre de 2026

1. Contexto de negocio y motivación

Una tienda online recibe visitas que no siempre se convierten en ventas. Analizar cómo difieren las sesiones con y sin compra permite formular hipótesis sobre la experiencia de navegación y orientar futuras pruebas de mejora. Este proyecto académico utiliza datos públicos históricos; no representa ventas de una empresa propia ni una medición actual del mercado.

2. Problema de Data Science

Pregunta: ¿Se puede clasificar si una sesión de navegación termina en compra a partir de su actividad, tipo de visitante y contexto temporal? La variable objetivo es **Revenue** (True/False), por lo que se plantea aprendizaje supervisado de clasificación binaria.

Hipótesis a contrastar: el patrón de navegación y el tipo de visitante contienen información sobre la compra. Se evaluará en una fase posterior contra un clasificador base, usando separación de entrenamiento/prueba estratificada y métricas como PR-AUC, precisión y recall. No se afirma todavía que exista un modelo eficaz ni un efecto causal.

Alcance temporal: las variables agregadas describen una sesión completa. El primer modelo será retrospectivo; para una intervención en tiempo real se necesitaría una instantánea anterior a la compra. Se excluirá PageValues hasta demostrar su disponibilidad sin información del resultado. No se usarán identificadores personales.

3. Ficha técnica y factibilidad

Propiedad	Verificación
Dataset	Online Shoppers Purchasing Intention Dataset
Fuente	UCI Machine Learning Repository; Sakar y Kastro (2018)
Observaciones	12.330 sesiones
Variables	18 columnas: 17 explicativas y Revenue como objetivo
Archivo	online_shoppers_intention.csv; lectura local con pandas
Clase positiva	1.908 sesiones con compra (15,47 %)
Calidad inicial	0 valores nulos; 125 filas con valores repetidos que requieren revisión
Licencia	CC BY 4.0; conservar atribución a autores y UCI

Fuente pública: [UCI - ficha y descarga del dataset](#). DOI: [10.24432/C5F88Q](#). Consulta y descarga: 29/09/2026.

El archivo supera los mínimos de 5.000 registros y 12 variables. Los conteos se verificaron al leer el CSV. Las sesiones corresponden al período histórico descrito por la fuente, que no informa aquí un año calendario completo para cada registro. No deben interpretarse como clientes actuales de una tienda.

4. Diccionario preliminar

Variable	Tipo / rol	Interpretación
Revenue	Booleana; objetivo	Indica si la sesión terminó en compra.
ProductRelated	Entera; conteo	Páginas de producto visitadas.
ProductRelated_Duration	Real; segundos	Tiempo acumulado en páginas de producto.
BounceRates	Real; proporción	Métrica de rebote asociada a páginas visitadas.
ExitRates	Real; proporción	Métrica de salida asociada a páginas visitadas.
VisitorType	Categoría nominal	Visitante nuevo, recurrente u otro.
Month	Categoría temporal	Mes registrado; no constituye una fecha completa.
Weekend	Booleana	La sesión ocurrió en fin de semana.
TrafficType	Código nominal	Categoría de procedencia del tráfico.
PageValues	Real	Valor de páginas; se excluye del modelo por posible fuga de información.

5. Plan de trabajo y límites

Se conservará el CSV original. Primero se inspeccionarán tipos, nulos y rangos; luego se preparará una copia con categorías explícitas y reglas de selección documentadas. Los ceros en conteos o duraciones no se convertirán automáticamente en faltantes. Los códigos de navegador, región, sistema operativo y tráfico son categorías, aunque se lean como enteros.

La clase positiva es minoritaria: accuracy por sí sola puede ocultar un modelo que siempre prediga no compra. Los 125 registros idénticos en valores no se eliminarán sin un identificador de sesión: podrían corresponder a usuarios distintos. Antes de evaluar modelos se revisará una partición que mantenga patrones idénticos en el mismo grupo para evitar optimismo.

Reproducibilidad

El repositorio incluye el CSV original, notebooks ejecutados, requisitos y este documento. Huella SHA-256 del CSV:

b3055ee355f59134d851d32641183cb4a8b45def7124d2f50442a042f358e0d9

Atribución: Sakar, C. y Kastro, Y. (2018). Online Shoppers Purchasing Intention Dataset. UCI Machine Learning Repository. CC BY 4.0. Los informes y transformaciones de este proyecto son elaboraciones propias sobre esa fuente.