

TechWorld: plan de preprocesamiento

Mateo Sapia | Comisión 102390 | 1 de octubre de 2026

Caso ficticio planteado por la consigna. No se recibió un CSV real: se proponen reglas y controles, sin inventar resultados de limpieza.

1. Tipos de variables

Campo	Clasificación y uso
ID_Transaccion	Identificador cualitativo nominal. Su formato numérico no justifica calcular promedios ni usarlo como cantidad.
Fecha	Variable temporal. Derivar día/mes solo después de resolver el formato.
Producto	Cualitativa nominal: etiquetas de productos.
Precio	Cuantitativa continua en una moneda y unidad por confirmar; N/A no es un precio.
Edad_Cliente	Cuantitativa discreta si representa años cumplidos; validar unidad y dominio.

2. Problemas y tratamiento

Problema	Regla propuesta y control
Fechas mezcladas	01/02 puede ser 1 de febrero o 2 de enero. Recuperar convención de cada sistema de origen; no confiar solo en inferencia automática. Fechas ambiguas se marcan y retienen en cuarentena hasta confirmación.
Mouse / ratón / MOUSE	Quitar espacios, normalizar mayúsculas/minúsculas y aplicar un diccionario validado de equivalencias. No fusionar productos distintos por parecido textual; conservar valor original.
Precio N/A	Convertir a nulo y comprobar moneda, separador decimal y si incluye impuestos. Preferir recuperación desde catálogo de la fecha; si se imputa para un modelo, mediana por producto ajustada solo con train y flag de imputación.
Edad negativa o >150	Marcar como inválida y buscar corrección en el origen. No sustituir por cero ni truncar a 150. Si no se recupera, usar nulo; revisar política de uso y privacidad.

3. Auditoría y prevención de errores

Conservar un archivo crudo inmutable y una copia transformada. Registrar filas afectadas por regla, porcentaje de nulos y cambios de etiquetas. Revisar unicidad de ID_Transaccion: si hay varias líneas por venta, una clave compuesta puede ser correcta. Eliminar repeticiones solo después de definir qué representa una fila.

Validar fechas contra el período del archivo, no adivinar cuál de los formatos es correcto. Un precio cero puede ser promoción y un importe negativo puede ser devolución: requieren reglas del negocio. Los atípicos estadísticos no se borran automáticamente. Separar train/test antes de aprender medianas, escalas o diccionarios de frecuencia.

4. Muestra y población

La población objetivo son las operaciones de las 50 sucursales en un período definido. La sucursal central es una muestra por conveniencia: puede tener más tráfico, mayor surtido, precios diferentes y clientes con otro nivel de ingreso. Un modelo aprendido allí podría sobreestimar ventas nacionales o fallar en sucursales pequeñas.

Solicitar una muestra estratificada por región, tamaño de sucursal y canal, con períodos comparables. Incluir todas las sucursales si el volumen lo permite. Si el diseño es desigual, ponderar según la población objetivo. Reservar sucursales y períodos posteriores para validación, y reportar desempeño por segmento. Un solo mes tampoco permite aprender estacionalidad anual.

Criterio de salida

El dataset se considera listo cuando las reglas están documentadas, los casos ambiguos están identificados, los totales se reconcilian y se conoce qué parte de la población queda representada. La ausencia de nulos no alcanza para garantizar calidad.