

Evaluación comparativa de intención de compra

Mateo Sapia | Comisión 102390 | 1 de octubre de 2026


Se modelan 12,167 patrones tras el saneamiento y la retirada de 125 repeticiones exactas. Train: 9,733; test reservado: 2,434, con 381 compras. Hashes sin la etiqueta agrupan predictores idénticos; no hay grupos compartidos entre particiones.

Imputación, escalado y One-Hot Encoding se ajustan dentro de cada fold. No se usa PageValues. Regresión logística balanceada $C=1$; Random Forest de 150 árboles, búsqueda en profundidad [6,12,None] y hoja mínima [3,8]. Selección por AP media en tres folds de train; test evaluado al final.

Modelo	Precisión	Recall	F1	AUC ROC	AP
Regresión logística	0.271	0.732	0.395	0.742	0.314
Random Forest	0.348	0.559	0.429	0.778	0.378


Métricas de la clase compra con umbral 0,50 fijado previamente. AP resume precisión-recall y no es AUC ROC. Baseline siempre no compra: accuracy 0,843 y F1 0; la accuracy aislada oculta la clase positiva.

Matrices de confusión - test, n=2,434




Filas = resultado real; columnas = predicción. La logística detecta 279 compras y el bosque 213, pero genera 751 falsos positivos frente a 399 del bosque. El mayor recall de la logística tiene un costo en precisión.

Curvas ROC: capacidad de ordenar casos



AUC ROC: 0,742 para logística y 0,778 para Random Forest. Describe separación de clases al variar el umbral. No equivale al porcentaje de predicciones correctas ni prueba que las probabilidades estén calibradas.

La clase minoritaria exige otra mirada



AP de test: 0,314 y 0,378; la prevalencia es 0,157. Ambos rankings superan esa referencia en este archivo, pero su precisión operativa sigue siendo limitada.

Elección técnica y decisión de negocio

Random Forest fue seleccionado por AP de validación cruzada: 0,377 frente a 0,322 de logística. La mejor grilla eligió profundidad sin límite y al menos 8 muestras por hoja. Se recomienda como candidato de un piloto retrospectivo, no como despliegue autónomo validado.

Si el objetivo hipotético es detectar intención para ofrecer asistencia de bajo costo, los falsos negativos son oportunidades no detectadas. Sin embargo, los falsos positivos consumen capacidad de atención. El bosque tiene mejor precisión y F1, pero menor recall al umbral 0,50. Si el negocio prioriza casi exclusivamente recall, habría que comparar umbrales en validación antes de elegir una política; no se decide solo por AUC.

Con el bosque, 168 compras de test quedaron sin detectar y 399 sesiones sin compra se marcaron positivas. No se conocen costos ni eficacia de una acción comercial: no se atribuye ahorro ni incremento de ventas. Una reducción del umbral puede mejorar recall y empeorar precisión; debe medirse con datos nuevos.

Límites y próximos controles

Las variables agregan la sesión completa. Para actuar durante la sesión hay que fijar un corte temporal y reconstruir las features disponibles entonces. Faltan ID de usuario y fecha exacta, por lo que no se puede verificar independencia entre personas ni validar por tiempo. Se requiere medir estabilidad en otro período, sensibilidad a deduplicación, calibración y costos de error.

Fuente: Sakar y Kastro (2018), UCI Online Shoppers Purchasing Intention, DOI 10.24432/C5F88Q, CC BY 4.0. CSV descargado el 29/09/2026; cálculo reproducible en `Sapia_Mateo_Final.ipynb`.

Código, outputs, partición y comprobaciones en `Sapia_Mateo_Final.ipynb`; tablas exactas en `metricas_test.csv` y `resultados_final.json`.