

Segmentación de oyentes: diseño no supervisado

Mateo Sapia | Comisión 102390 | 1 de octubre de 2026

Caso hipotético: 500.000 usuarios de una plataforma musical, sin etiquetas. No se ejecutó clustering sobre datos que no fueron suministrados.

1. Algoritmo y representación

Elegiría K-Means como primer baseline escalable, y su variante MiniBatchKMeans para ensayos con 500.000 filas. Transformaría géneros a proporciones de escucha y escalaría horas y cantidad de listas. No calcularía distancias sobre nombres de ciudades o códigos geográficos tratados como números.

Criterio	K-Means	DBSCAN
Forma de grupos	Favorece grupos compactos alrededor de centroides; puede fallar con formas alargadas o densidades diferentes.	Puede recuperar formas no convexas mediante vecindad y densidad.
Ruido	Asigna cada punto a un grupo; atípicos pueden mover centroides.	Marca puntos aislados como ruido; necesita eps y min_samples adecuados.
Escala y alta dimensión	Baseline práctico; sensible a escalas e inicialización. Probar varias semillas y k.	Las vecindades pueden volverse poco informativas en alta dimensión; puede exigir memoria elevada.

No impondría cinco grupos por intuición: compararía varios k con silueta, estabilidad por semilla y tamaño útil de cada segmento. Si el análisis mostrara formas complejas y ruido relevante, evaluaría DBSCAN en una muestra representativa y comprobaría su viabilidad antes de escalar.

2. PCA con 100 variables

Tras imputar y estandarizar variables numéricas, ajustaría PCA para reducir redundancia. Elegiría componentes por varianza explicada acumulada y estabilidad del clustering, no siempre dos. Usaría dos componentes para una vista exploratoria, aclarando cuánta variación conserva. Menos dimensiones pueden reducir costo de distancias, aunque PCA también cuesta y puede eliminar señales pequeñas útiles.

3. De cinco grupos a segmentos útiles

Si el resultado final devuelve cinco grupos, calcularía por grupo tamaño, medianas y distribución de horas, listas y proporciones de géneros. Revisaría usuarios cercanos al centro y casos frontera. Elegiría nombres descriptivos basados en patrones observados, como «escucha frecuente con muchas listas» solo si los datos lo sostienen, evitando etiquetas de personalidad.

Contrastar con Marketing si cada grupo permite una acción concreta y respetuosa: mejorar recomendaciones, ordenar contenidos o investigar necesidades. Medir estabilidad entre meses y comprobar en un experimento si una acción mejora una métrica acordada sin empeorar satisfacción. Una buena silueta no garantiza utilidad comercial.

4. Ética y sesgos

La ubicación y edad pueden actuar como proxies de ingreso o acceso a conectividad. Los grupos podrían reproducir exclusión o recibir ofertas desiguales. Comenzaría segmentando por comportamiento; reservaría edad y ubicación para auditar cobertura y diferencias cuando exista una base legítima para ese uso. Minimizar datos, controlar acceso y evitar inferir atributos sensibles a partir de preferencias musicales.

Revisar representatividad por región y dispositivo, documentar exclusiones y dar revisión humana a las campañas. No interpretar un grupo como una identidad fija ni usarlo para decisiones de alto impacto sobre personas.

Referencia técnica

Scikit-learn: clustering y PCA. Consulta: 01/10/2026. Propuesta conceptual, sin métricas simuladas ni nombres atribuidos a grupos reales.